

# 一种增量向量支持向量机学习算法

陈沅涛<sup>1,2</sup>, 徐蔚鸿<sup>1,2</sup>, 吴佳英<sup>1,2</sup>

(1. 南京理工大学 计算机科学与技术学院, 江苏 南京 210094;

2. 长沙理工大学 计算机与通信工程学院, 湖南 长沙 410114)

**摘要:**针对传统支持向量机方法执行效率低、耗时长的问题, 该文提出一种基于增量向量支持向量机学习(IV-SVM)方法。对训练样本集在核空间的增量向量进行训练, 获得初始支持向量机分类器。利用该分类器在 Karush-Kuhn-Tucker(KKT)条件下对初始训练样本进行修剪得到约减集, 再用该约减集对初始分类器进一步加工, 得到最终的支持向量机分类器。仿真结果表明, 与传统支持向量机方法相比, 在保证支持向量机泛化能力的条件下, IV-SVM 可有效降低大容量数据样本的支持向量机训练时间。

**关键词:**支持向量机; 增量向量; 修剪; 约减集

**中图分类号:**TP391      **文章编号:**1005-9830(2012)05-0873-06

## Incremental Vector Support Vector Machine Learning Algorithm

CHEN Yuan-tao<sup>1,2</sup>, XU Wei-hong<sup>1,2</sup>, WU Jia-ying<sup>1,2</sup>

(1. School of Computer Science and Technology, NUST, Nanjing 210094, China;

2. School of Computer and Communicational Engineering, Changsha University of Science and Technology, Changsha 410114, China)

**Abstract:** In view of that the common support vector machine (SVM) learning algorithm is time-consuming and lower in efficiency, an algorithm of incremental vector support vector machine (IV-SVM) learning algorithm is put forward here. A primary SVM classifier is acquired based on the selected increment vectors in the kernel space. According to Karush-Kuhn-Tucker (KKT) conditions, the original training samples are pruned through the primary SVM classifier. The final SVM classifier is obtained by training the primary SVM classifier with reduction samples. Simulation experiments show that, compared with the common support vector machine, IV-SVM can reduce the training time of large capacity data samples support vector machine.

**Key words:** support vector machine; increment vector; pruning; some clips

收稿日期: 2011-08-02      修回日期: 2011-10-11

**基金项目:** 国家自然科学基金青年科学基金(61001004); 湖南省自然科学基金(09JJ6094); 湖南省教育厅科研青年项目(12B005); 长沙市科技计划重点项目(K1104022-11); 湖南省科技计划项目(2012GK3056; 2011SK3079)

**作者简介:** 陈沅涛(1980-), 男, 博士生, 讲师, 主要研究方向: 模式识别与图像处理, E-mail: yufeng8552@qq.com。

支持向量机的方法解决了针对小样本的机器学习任务,但由于无法预知所有支持向量,训练时只能对所有的样本通过解非线性二次规划的方法反复迭代,因此普通的支持向量机方法学习费时。本文在总结文献[1-4]已有算法基础上,借鉴人类学习的原理,提出一种基于增量支持向量机(Incremental vector support vector machine, IV-SVM)学习算法。针对大规模训练样本,IV-SVM 算法在保证支持向量机泛化能力的前提下,有效节省了训练所需时间。

## 1 增量向量抽取

以支持向量机对样本分类为例进行分析,从支持向量机训练的过程可以知道,只有很少一部分被称为支持向量的样本对支持向量机的决策起着决定性作用。而目前常用的支持向量机学习算法都是对所有的样本进行训练,由于解二次规划的复杂度随着样本数量的增加而显著增长,这就造成了支持向量机寻优的速度非常缓慢。分析支持向量的内在原理可知,如果把每一类训练样本看成是一个凸包集合的话,通过求解二次规划问题所得出的支持向量,大部分都位于两凸包相对部分的增量上<sup>[2]</sup>。而且对多数数据样本而言,两凸包相对部分的增量向量(Increment vector, IV)在整个样本中仅占很小的比例。因此,如果能够事先找到增量向量,就可以节省分类器寻找支持向量的时间,从而达到优化支持向量机的训练目的。

## 2 增量式学习策略

### 2.1 初始分类器分析

利用增量向量对支持向量机进行训练,由于训练样本的个数显著减少,算法收敛的速度大大提高,而且由于增量向量中包含了许多支持向量,训练所得初始分类器也具备一定的泛化能力。但在实际应用中,由于训练样本集中于两类样本的增量上,而增量向量中并未包含所有的支持向量,因此训练所得初始分类器相对比较粗糙,对应的泛化能力往往不太理想。

上述过程与人类的学习比较类似,假设训练样本集对应于一个从未见过的陌生人,人脑在辨识时不会对陌生身上的每一部分对予以关注,一般情形是首先对陌生人的轮廓,如身高、体型等产生大概

认识。但如果没有人脸、四肢等关键部分的观察,对陌生人的认识就会一直停留在轮廓的记忆里。比较而言,陌生人的轮廓正如训练样本中的增量向量,初始分类器则存储了陌生人的轮廓特征,如何找到人脸、四肢等关键样本对初始分类器进一步训练,提高其泛化认识能力就成了一个极为关键的问题。一种简单的做法是将新样本全部加进来,重新开始进行训练,但是这种做法否定了前面所有的工作,等于完全抛弃了已有的知识,也是有悖于常理的。如果把初始分类器看作已经训练好的支持向量机,而把那些非增量样本看作是新增的训练样本,那么正确的做法就转化为找到一个良好的增量式支持向量机学习策略,充分利用新增样本对初始分类器进行积累性的学习。

### 2.2 支持向量机基本属性

为了找到支持向量机对新增样本的学习策略,首先研究支持向量机的一些基本属性。

**定理1** 在分类支持向量机中, $\alpha$  为 Lagrange 乘子,则  $\alpha=0$  对应的样本分布在分类器分类间隔之外,包括等高线  $f(x)>1$  以及  $f(x)<-1$  对应的区域。 $0\leq\alpha\leq C$  对应的样本位于分类间隔之上,包括等高线  $f(x)=1$  以及等高线  $f(x)=-1$ 。而  $\alpha=C$  对应的样本位于分类间隔之内,包括等高线  $-1\leq f(x)\leq 1$  对应的区域内<sup>[3]</sup>。

对新增训练样本进行分析,在 IV-SVM 中,新增样本集主要对应那些非增量向量。由于新增样本集并未得到原支持向量机的训练,首先需要判别的是,新增样本集是否含有原样本集所不包含的信息。如果答案是肯定的,则必须考虑以下3个问题,到底是哪些新增样本使得原支持向量机发生了变化?这种变化的结果如何?最后该如何从新增样本集中选择训练样本并确定最终的训练样本集?

设原始训练样本集为  $X_0$ ,训练所得初始支持向量机分类器  $\Omega^0$ ,对应支持向量集  $X_0^{SV}$ ;新增训练样本集  $X_1$ ,样本集  $X_0\cup X_1$  训练所得支持向量机分类器  $\Omega^1$ ,对应新的支持向量集  $X_1^{SV[4]}$ 。则下述定理对上面的问题进行了初步的回答。

**定理2** 如果  $X_1$  中的样本均满足  $\Omega^0$  的 KKT 条件,则  $X_1\cap X_0^{SV}=\emptyset$ ,即  $X_1$  中不存在新的支持向量;反之,如果  $X_1$  中有样本违背了  $\Omega^0$  的非线性最优规则问题的 Karush-Kuhn-Tucker (KKT) 最优化条件,则  $X_1\cap X_0^{SV}\neq\emptyset$ ,即  $X_1$  中肯定存在部分或全部为新的支持向量<sup>[5]</sup>。

考虑到支持向量机的判决函数仅与支持向量有关,训练时就可以仅考虑那些违反 KKT 条件的样本集,这样在大大简化训练样本集的同时,还可以达到积累性学习的目的。具体来说,在对新增样本集  $X_1$  进行训练时,可以将  $X_1$  分解为  $X_1^V$  与  $X_1^S$ ,  $X_1^V$  表示违反 KKT 条件的样本集,  $X_1^S$  表示满足 KKT 条件的样本集。由定理 2 可知,  $X_1^S$  中没有违反 KKT 条件的样本,说明原支持向量机  $\Omega^0$  已经包含了  $X_1^S$  中样本的信息,则不需要对其进行重复学习。而样本集  $X_1^V$  违背了  $\Omega^0$  的 KKT 条件,说明  $\Omega^0$  中没有包含这部分样本的信息,因此选择对样本集  $X_0 \cup X_1^V$  进行学习。这种学习方法没有损失  $\Omega^0$  中包含的信息,是一种积累性的学习。对定理 2 中 KKT 条件进行分析,推出定理 3。

**定理 3** 新增训练样本违背 KKT 条件的充要条件为  $y_i f(x_i) \leq 1$ , 具体对应以下 3 类样本:

(1) 满足条件  $0 \leq y_i f(x_i) \leq 1$ , 对应样本位于分类间隔中或分类决策面上, 能被原支持向量机分类器正确分类, 与本类样本一起位于最优分类决策面的同侧;

(2) 满足条件  $-1 \leq y_i f(x_i) < 0$ , 对应样本位于分类间隔中或分类决策面上, 被原支持向量机分类器错误分类, 与本类样本分别位于最优分类决策面的异侧;

(3) 满足条件  $y_i f(x_i) < -1$ , 对应样本位于分类间隔外, 被原支持向量机分类器错误分类, 与本类样本分别位于最优分类决策面的异侧。

定理 3 表明, 支持向量机在最大化分类增量的过程中, 其几何意义非常明确而且直观。定理 3 描述的具体情况分别对应图 1 中 1 类、2 类以及 3 类样本。定理 2 与 3 回答前面提出的第 1 个问题, 下面的定理着重回答第 2 个问题。




图 1 新增样本前后训练对比图

**定理 4** 新增样本存在违背 KKT 条件的样本, 则原样本集中非支持向量有可能转化为支持向量, 而原样本集中支持向量也有可能转化为非

支持向量<sup>[6]</sup>。

图 1 中样本集  $X_0$  训练结果对应等高线  $-1$ 、 $0$ 、 $+1$  三条实线, 样本集  $X_0 \cup X_1$  训练结果对应等高线  $-1$ 、 $0$ 、 $+1$  三条虚线, 两次训练产生的支持向量均用圆圈标注。

从图 1 可以看出, 样本集  $X_0$  经过第一次训练得到初始支持向量机,  $(S_1, S_4)$  成为支持向量, 加入新增样本集  $X_1 = (S_2, S_5)$  后, 样本集  $X_0 \cup X_1$  通过训练得到新的支持向量机, 对应支持向量变为  $(S_1, S_3, S_5)$ , 与原支持向量相比, 样本  $S_1$  在两次训练中均为支持向量。样本  $S_3$  在原支持向量机中为非支持向量, 第二次训练后则成为支持向量, 对应定理 4 中描述: 原样本集中非支持向量有可能转化为支持向量。反之, 样本  $S_4$  在原样本集中为支持向量, 在新支持向量机中则成为非支持向量。从图 1 可以看出, 新增样本  $S_2, S_5$  均违背原支持向量机的 KKT 条件, 其中  $S_5$  成为新的支持向量。定理 4 说明, 在增量学习中, 如果只考虑新增样本和原样本集中的支持向量机, 则有可能会丢失原来样本中的信息, 而且也不能保证十分有效地舍弃无用的样本, 两种情况分别对应图 1 中样本  $S_3$  与  $S_4$ 。定理 4 很好地描述了前面提出的第二个问题。

### 3 IV-SVM 学习策略

基于定理 1-4, 可以很快确定最终训练样本集, 即回答前面提出的第三个问题。对应过程可以分为两步, 首先根据定理 2 和定理 3, 选择那些违背原支持向量机 KKT 条件的增量样本  $X_1^V$ , 然后根据定理 4, 保留那些原始的训练样本  $X_0$ , 在 IV-SVM 中对应那些核空间的增量向量, 而最后的训练样本集将变为  $X_0 \cup X_1^V$ 。

IV-SVM 算法的具体学习策略流程如下

(1) 根据  $d^F(x_1, x_2) = \sqrt{K(x_1, x_1) - 2K(x_1, x_2) + K(x_2, x_2)}$  计算初始训练样本集合的特征空间距离;

(2) 通过判别  $d(x_{li}, x_{lj})$  的最大值和最小值来获取增量向量样本集合  $X_0$ ;

(3) 通过针对增量向量样本集合  $X_0$  进行相关训练, 得到初始化分类器  $\Omega^0$ ;

(4) 利用初始化分类器  $\Omega^0$  对增量向量的训练样本集合  $X_1$  进行判定, 在  $X_1$  样本集合中寻找那些不符合 KKT 条件的新增加样本构成集

合  $X_1^V$ ;

(5) 利用样本集合  $X_0 \cup X_1^V$  执行训练, 从而获取经过学习的分类器  $\Omega^I$ 。在实际应用中, 违背 KKT 条件的判别  $y_i f(x_i) \leq 1$  可以适当放宽一些, 如采用  $\varepsilon \leq |y_i f(x_i)| \leq 1$ , 选取的依据来自于支持向量机日常训练的经验, 即违反 KKT 条件的**新增样本**中, 那些位于分类间隔中且靠近 +1、-1 分类决策面的样本, 最有可能成为新支持向量机的支持向量。样本修剪的程度通过参数  $\varepsilon$  调节, 如图 2 所示, 图中  $\varepsilon=0.4$ , 样本选取区域如图中箭头所示, 这样选取的好处是可以进一步加快 IV-SVM 的训练时间, 并在多数情况下能获得不错的泛化能力。文献[7]介绍了一种类似的方法, 但文献描述的方法没有说明原支持向量机训练样本的选取方法, 样本的修剪策略是  $1-\varepsilon \leq |f(x_i)| \leq 1+\varepsilon$ ,  $0<\varepsilon<1$ , 即只保留靠近 +1、-1 分类决策面一定距离的样本点, 距离的大小通过  $\varepsilon$  调节, 这样的修剪带有很大的随意性, 没有严格的理论依据。




图 2 一种简化的 IV-SVM 算法图

### 4 仿真计算结果与分析


下面的仿真计算主要对常用 SVM 算法与 IV-SVM 算法的多项运行指标进行比较, 重点考察两类算法的运行时间与测试正确率。常用 SVM 算法基于 S. Canu 等提供的基于 Matlab 的 SVM 工具箱<sup>[8]</sup>, 方法解二次规则问题采用的是活动集约束方法 (Active constraints method)。

**仿真计算 1** 本仿真计算比较 SVM 与 IV-SVM 的训练时间与测试正确率。训练与测试样本由 S Canu 等提供的高斯随机分布函数产生, 样本为二维特征向量, 二维数据间方差类似, 均值不同。仿真计算中样本数据从 100 逐渐增加到 1 000。


仿真计算结果如图 3 所示, 图 3(a) 对应两种算法训练时间的对比, 从图 3(a) 可以看出, 在样本数目小于 400 时, SVM 与 IV-SVM 的运行时间

比较接近, 在样本数为 100 及 200 处, SVM 略好。但当样本数目超过 400 以后, IV-SVM 在所有的样本数目处都表现出明显的优势, 而且从运行时间的总体趋势来看, SVM 随着训练样本数目的增加, 训练时间迅速增长。而 IV-SVM 的训练时间与训练样本数目之间并没有类似的正比关系, 考虑到 IV-SVM 的训练样本主要来自于增量向量样本与违背 KKT 条件的样本, 则上述现象不难理解。图 3(b) 描述了与运行时间同步对照的测试正确率, 从图 3(b) 中可以看出, IV-SVM 的测试正确率与 SVM 基本持平, 在某些地方要略高一些, 如图中样本数目等于 700 时。综合图 3(a)、(b) 可以看出, 随着样本数目的增加, IV-SVM 在保证分类器分类精度的情况下, 能够有效减少分类器的训练时间。

图 3(b) 中带钻石的虚线反映文献[9]中描述方法的对应测试正确率, 该方法直接采用增量向量样本进行训练得到支持向量机, 正确率为 100%, 但实际上对支持向量机来说, 训练正确率并没有太多的意义, 只要适当调节支持向量机的相关参数, 支持向量机一般都会达到很高的训练正确率, 支持向量机最关键的还是其泛化能力。



(a) 训练时间



(b) 测试正确率

图 3 SVM 与 IV-SVM 训练时间和测试正确率对比图

**仿真计算 2** 本仿真计算采用与仿真计算 1 相同的数据源, 由于随机数的影响, 每次产生的样本不同, 但总样本数目固定为 600。方法分别比较了 SVM 与 IV-SVM 的训练时间, 测试正确率, 支持向量 SV 数, 训练样本数, 以及增量向量数。

从表 1 可以看出, 总体上说, IV-SVM 在训练时间较短的情况下, 保持了较高的测试正确率, 其中第 5 组测试正确率略高一些。而从两种方法对



应的支持向量及训练样本数可以看出,选取增量向量不需要涉及 SVM 运算这一很费时的工  
作,但却找到了大部分的支持向量;同时 IV-SVM 的训练样本主要来自于增量向量样本以及违反 KKT 条件的样本,而在多数情况下,这两者的总和还是远远小于原始训练样本的数目,这就解释了为什

么 IV-SVM 的训练时间总体要少于 SVM 的训练时间。这一点从第 2 组训练样本也可以看出,第 2 组是唯一的一组 IV-SVM 训练时间略长,而其训练样本相对于其他组也是最多的。可见,由于该组违反 KKT 条件的新增样本较多,从而相应的训练样本较多,导致了最终的训练时间要多些。

表 1 SVM 与 IV-SVM 综合指标对比

组次	SVM				IV-SVM				IV 数
	时间	正确率/%	SV 数	样本数	时间	正确率/%	SV 数	样本数	
1	0.860	99	20	600	0.469	99	20	63	20
2	1.328	96.5	40		1.562	96.5	40	580	32
3	1.078	98	32		0.875	98	28	223	30
4	1.469	99	45		1.234	99	45	429	36
5	1.157	98.5	41		0.875	99	39	281	34
6	1.172	97.5	42		0.765	97.5	42	90	40
7	0.953	98	28		0.687	98	28	273	28
8	1.375	96	50		1.125	96	52	293	44
9	1.219	97.5	45		1.078	97.5	46	330	41
10	1.250	95.5	41		0.797	95.5	41	173	36

总之 IV-SVM 在较少训练样本的条件下,通过增量向量样本以及违反 KKT 条件的样本,找到了对支持向量机决策函数至关重要的支持向量,并在较少训练时间的情况下,仍然能够保持较高的测试正确率。

仿真计算 3 本仿真计算采用标准测试库,即心脏病、乳腺癌、甲状腺病以及巨人症 4 种疾病的诊断数据。4 种样本的训练样本数据都比较少,最多不超过 200。训练时 IV-SVM 算法的 KKT 判别条件采用  $\varepsilon \leq |y f(x_i)| \leq 1$ ,选取  $\varepsilon = 0.4$ ,对应仿真计算结果如图 4 所示。

从图 4(a)可以看出,1、2、4 类训练样本的训练时间要略少一些,3 类训练样本训练时间则略多些,对比图 4(c)可以看出,3 类训练样本本身数目最少(小于 150),而其通过 SVM 训练的时间也是最少的,在此情况下,IV-SVM 的时间优势就难以体现了,这与图 4 结论一致,即 IV-SVM 在训练样本数目较多的情况下优势最为明显。比较图 4(b)正确率可以看出,总体上 IV-SVM 与 SVM 的测试正确率持平,其中样本 1 测试正确率略高些,样本 2 略低些。难得可贵的是,IV-SVM 在样本 1 训练数目不多的情况下(小于 200),压缩训练时间达到一半以上,同时保持了较高的正确率。4 类训练样本对应的支持向量与增量向量数目如图 4(d)所示,从图 4(d)可以看出 IV-SVM 能够通过增量向量 IV 找到大部分支持向量。

5 结束语

本文给出了一种增量式支持向量机(IV-SVM)算法,对训练样本,尤其是大容量训练样本,IV-SVM 在保证泛化能力的前提下,有效地节约了训练的时间。

基于本文的方法还有许多需要研究的问题,例如增量向量,尤其是核空间的增量向量,它们与支持向量的准确关系需要进一步理论分析,以便寻找




图 4 IV-SVM 与 SVM 各指标对比图

到更好的训练样本,目标是只需一次修剪和训练就可使 SVM 达到或超过原样本集训练对应的各项指标;同时,样本规模在什么范围或符合什么分布时 IV-SVM 比常用 SVM 优势更明显,增量样本的选取是否存在更合理的手段等都需要进一步研究。

### 参考文献:

- [1] Platt J C, Scholkopf B, Burges C J C, et al. Fast training of SVMs using sequential minimal optimization [A]. Advances in Kernel Methods Support Vector Learning [C]. Massachusetts, US: MIT Press, 1998: 185-208.
- [2] Keerthi S, Shevade S, Bhattacharyya C, et al. Improvements to platt's SMO algorithm for SVM classifier design [J]. Neural Networks, 1999, 6(12): 783-789.
- [3] Zhang Ling, Zhang Bo. A geometrical representation of McCulloch-pitts neural model and its applications [J]. IEEE Transactions on Neural Networks, 1999, 10(4): 925-929.
- [4] 孙林, 杨世元. 基于 LS-SVM 的温度传感器非线性关系拟合及参考端温度补偿 [J]. 应用科学学报, 27(6): 616-622.  
Sun Lin, Yang Shiyuan. Fitting of non-linear relation of temperature sensor and reference temperature compensation based on LS-SVM [J]. Journal of Applied Sciences, 2009, 27(6): 616-622.
- [5] Zhang Li, Zhou Weida, Jiao Licheng. Pre-extracting support vectors for support vector machine [A]. WCCC-ICSP Proceedings of 5th International Conference on Signal Processing [C]. Beijing: Publishing House Electronics Industry, 2000: 1427-1431.
- [6] 姜慧妍, 宗茂, 刘相莹. 基于 ACO-SVM 的软件缺陷预测模型的研究 [J]. 计算机学报, 2011, 34(6): 1148-1154.  
Jiang Huiyan, Zong Mao, Liu Xiangying. Research of software defect prediction model based on ACO-SVM [J]. Chinese Journal of Computers, 2011, 34(6): 1148-1154.
- [7] 李红莲, 王春花, 袁保宗, 等. 针对大规模训练集的支持向量机的学习策略 [J]. 计算机学报, 2004, 27(5): 715-719.  
Li Honglian, Wang Chunhua, Yuan Baozong, et al. A learning strategy of SVM used to large training set [J]. Chinese Journal of Computers, 2004, 27(5): 715-719.
- [8] Canu S, Grandvalet Y, Guigue V, et al. SVM and kernel methods Matlab toolbox [EB/OL]. <http://asi.insa-rouen.fr/~arakotom/toolbox/>, 2005-12-20.
- [9] 张培林, 钱林方, 曹建军, 等. 基于蚁群算法的支持向量机参数优化 [J]. 南京理工大学学报, 2009, 33(4): 464-468.  
Zhang Peilin, Qian Linfang, Cao Jianjun, et al. Parameter optimization of support vector machine based on ant colony optimization algorithm [J]. Journal of Nanjing University of Science and Technology, 2009, 33(4): 464-468.
- [10] 邢永忠, 吴晓蓓, 徐志良. 基于矢量基学习的自适应迭代最小二乘支持向量机回归算法 [J]. 南京理工大学学报, 2011, 35(3): 328-333.  
Xing Yongzhong, Wu Xiaobei, Xu Zhiliang. Adaptive iterative LS-SVM regression algorithm based on vector base learning [J]. Journal of Nanjing University of Science and Technology, 2011, 35(3): 328-333.

作者：[陈沅涛](#)，[徐蔚鸿](#)，[吴佳英](#)，[CHEN Yuan-tao](#)，[XU Wei-hong](#)，[WU Jia-ying](#)  
作者单位：[南京理工大学计算机科学与技术学院, 江苏南京210094](#);[长沙理工大学计算机与通信工程学院, 湖南长沙410114](#)  
刊名：[南京理工大学学报（自然科学版）](#)   
英文刊名：[Journal of Nanjing University of Science and Technology](#)  
年，卷(期)：2012, 36(5)  
被引用次数：6次

参考文献(10条)

1. [Platt J C;Scholkopf B;Burges C J C](#) Fast training of SVMs using sequential minimal optimization 1998
2. [Keerthi S;Shevade S;Bhattacharyya C](#) Improvements to platt's SMO algorithm for SVM classifier design 1999(12)
3. [Zhang Ling;Zhang Bo](#) Geometrical representation of McCulloch-Pitts neural model and its applications[外文期刊] 1999(4)
4. [孙林, 杨世元](#) 基于LS-SVM的温度传感器非线性关系拟合及参考端温度补偿[期刊论文]-[应用科学学报](#) 2009(6)
5. [Zhang Li;Zhou Weida;Jiao Licheng](#) Pre-extracting support vectors for support vector machine 2000
6. [姜慧研, 宗茂, 刘相莹](#) 基于ACO-SVM的软件缺陷预测模型的研究[期刊论文]-[计算机学报](#) 2011(6)
7. [李红莲, 王春花, 袁保宗, 朱占辉](#) 针对大规模训练集的支持向量机的学习策略[期刊论文]-[计算机学报](#) 2004(5)
8. [Canu S;Grandvalet Y;Guigue V](#) SVM and kernel methods Matlab toolbox 2005
9. [张培林, 钱林方, 曹建军, 任国全](#) 基于蚁群算法的支持向量机参数优化[期刊论文]-[南京理工大学学报（自然科学版）](#) 2009(4)
10. [邢永忠, 吴晓蓓, 徐志良](#) 基于矢量基学习的自适应迭代最小二乘支持向量机回归算法[期刊论文]-[南京理工大学学报（自然科学版）](#) 2011(3)

引证文献(3条)

1. [杜林钰](#) 支持向量机学习算法若干问题的研究[期刊论文]-[网友世界·云教育](#) 2014(19)
2. [陈义刚, 徐厚东](#) 基于支持向量机的变电设备缺陷发生率的预测及应用[期刊论文]-[四川电力技术](#) 2013(06)
3. [姜晖, 肖迪](#) Ncut聚类与增量支持向量机的SMB智能建模[期刊论文]-[计算机工程与设计](#) 2015(07)

引用本文格式：[陈沅涛, 徐蔚鸿, 吴佳英, CHEN Yuan-tao, XU Wei-hong, WU Jia-ying](#) 一种增量向量支持向量机学习算法[期刊论文]-[南京理工大学学报（自然科学版）](#) 2012(5)